

# Estimación de la generación de energía en granjas de convertidores de energía undimotriz mediante modelos sustitutos basado en aprendizaje automático

Andrés Flórez, Diego Rendón, Milton Cuervo

**Abstract**—La energía undimotriz, la cual busca aprovechar el oleaje y movimiento del océano para la generación de electricidad, tiene un gran potencial para el abastecimiento de las necesidades energéticas de la población del mundo. El aprovechamiento a gran escala enfrenta desafíos técnicos en el diseño y mantenimiento, esto se debe principalmente, a la complejidad en el modelamiento físico matemático de estos sistemas. Es por esto que han surgido estrategias de modelamiento sustituto a partir de las diferentes técnicas del aprendizaje automático.

A partir de un completo dataset, este proyecto busca aplicar las diversas técnicas vistas en el curso de Modelos y simulación de sistemas 2, con el objetivo de predecir la potencia total generada por un arreglo de WEC acorde a diferentes disposiciones geométricas.

**Palabras clave**—Wave Energy Converter (WEC), Wave Energy, Energía Undimotriz, Convertidor sumergido de tres anclajes, aprendizaje automático

## I. INTRODUCCIÓN

La energía undimotriz, también conocida como energía de las olas, es una fuente renovable que aprovecha el movimiento del océano para generar electricidad. Su potencial es significativo, especialmente en regiones costeras con alta actividad marítima, y representa una alternativa limpia frente a los combustibles fósiles. Sin embargo, su aprovechamiento a gran escala enfrenta desafíos técnicos y económicos, particularmente en el diseño y operación de granjas de energía compuestas por múltiples convertidores de energía undimotriz (WECs, por sus siglas en inglés).

La optimización de estas granjas requiere modelos capaces de predecir con precisión la potencia total generada, considerando complejas interacciones hidrodinámicas entre dispositivos. Dado el alto costo computacional de los modelos físicos detallados, se ha recurrido al uso de modelos sustitutos (surrogate models) basados en técnicas de aprendizaje automático. Estos modelos permiten estimaciones rápidas y suficientemente precisas, facilitando procesos de diseño, simulación y control en tiempo real. Este proyecto se enfoca en el desarrollo de un modelo sustituto para predecir la potencia

total generada por una granja de energía undimotriz, utilizando el dataset Large-scale Wave Energy Farm del repositorio UCI.

## II. DESCRIPCIÓN DEL PROBLEMA

El diseño y operación de granjas de energía undimotriz a gran escala implica la predicción precisa de la potencia generada por múltiples WECs distribuidos en el mar. Este proceso es complejo debido a las interacciones hidrodinámicas no lineales entre dispositivos, que afectan la eficiencia de conversión energética. Los modelos físicos detallados, como los basados en simulaciones CFD (Computational Fluid Dynamics), aunque precisos, son computacionalmente costosos y poco escalables para tareas de optimización o control en tiempo real. Acercamientos con modelamientos lineales más simples han tenido gran acogida en los trabajos de investigación del área y el dataset seleccionado es producto de la aplicación de dichos modelos para resolver el problema de optimización que describiremos posteriormente.

El dataset utilizado contiene 63,600 instancias y 149 variables, sin valores faltantes, pero con valores duplicados, lo que hace que el número de muestras aprovechables disminuya a una tercera parte, aún así, sus características lo hacen ideal para aplicar técnicas de aprendizaje automático. El objetivo es construir un modelo sustituto que, a partir de las variables de entrada que representan las posiciones de los WECs, prediga la potencia total generada por la granja. Este enfoque permite reducir significativamente el tiempo de simulación y facilita la exploración de configuraciones óptimas del sistema. El reto principal radica en capturar las relaciones complejas entre variables sin perder precisión, lo que requiere una cuidadosa selección de modelos, ajuste de hiperparámetros y validación rigurosa.

Las diferentes muestras se dividen en cuatro conjuntos de datos, basados en dos escenarios distintos de mareas definidos por localizaciones distintas; Peth y Sidney. Para cada localización se tienen datos para conjuntos de 49 convertidores y 100 convertidores. Las características corresponden a la disposición geométrica de los convertidores, descritas por coordenadas en el plano cartesiano  $X_1, Y_1, X_2, Y_2, \dots, X_i, Y_i, \dots, X_N, Y_N$ , las potencias individuales de cada convertidor  $Power_1, Power_2, \dots, Power_N$  donde  $N = 49$  ó  $N = 100$ , factor  $q$  y la potencia total generada por el conjunto de convertidores.

Los dos conjuntos de 49 convertidores componen un total de 54,000 mientras que las 9,595 muestras restantes corresponden

Octubre 24 de 2025. Universidad de Antioquia

Andrés Flórez, estudiante de ingeniería de sistemas de la Universidad de Antioquia (e-mail: andresf.florezc@udea.edu.co).

Diego Rendón, estudiante de ingeniería de sistemas de la Universidad de Antioquia (e-mail: diego.rendons@udea.edu.co).

Diego Rendón, estudiante de ingeniería de sistemas de la Universidad de Antioquia (e-mail: diego.rendons@udea.edu.co).

Milton Cuervo, estudiante de ingeniería de sistemas de la Universidad de Antioquia (e-mail: milton.cuervo@udea.edu.co).

a los datasets con información de 100 convertidores y son datos derivados de la investigación de Neshat, Mehdi et al [1]

Cabe señalar que existen gran cantidad de tipos de convertidores (WEC's) y que se pueden clasificar de acuerdo a su principio de funcionamiento [2]; cuerpo oscilante, columna oscilante de agua o convertidores de rompeolas. El dataset a trabajar contiene datos de unidades WEC, cuyo principio de operación es el de cuerpo oscilante y denominado convertidor totalmente sumergido de tres ataduras. Dicho convertidor consiste en una boya sumergida que se ancla al suelo marino mediante tres cuerdas. Es un tipo de absorbedor puntual donde cada anclaje se convierte en un punto de absorción por movimiento relativo. En la figura 1 se muestra un esquema general de dicho dispositivo.




Fig. 1. Esquematación general del convertidor de energía de tipo totalmente sumergido de tres anclajes Tomado de [3]

### III. ESTADO DEL ARTE

#### A. Optimisation of large wave farms using a multi-strategy evolutionary framework [1]

Este trabajo propone un enfoque de multi-estrategia para optimizar la disposición de los convertidores y es el origen del dataset seleccionado. El objetivo principal es la utilización de algoritmos genéticos combinados con técnicas de aprendizaje para reducir el costo computacional de las simulaciones y así lograr el modelamiento de grandes arreglos compuestos de más de 20 convertidores.

Tabla I  
PARÁMETROS DE CONVERTIDORES

Parámetro	Valor
Radio (m)	5
Profundidad sumergida (m)	5
Profundidad agua (m)	30
masa (ton)	376
Volumen ( $m^3$ )	523.60
ángulo de anclaje ( $^\circ$ )	55

Los WEC simulados son del mismo tipo y características, a saber, consisten en convertidores de tipo boya totalmente sumergidos y con tres anclajes (Basados en el diseño CETO 6) pero cuyo cuerpo flotante es una esfera. Los parámetros de las simulaciones corresponden a los mostrados en la tabla 1.

Estos valores son reportados en trabajos previos de los autores [4] y basado en los modelos detallados en [5]

El trabajo resuelve fundamentalmente un problema de optimización, el de encontrar el layout que maximiza la potencia promedio anual generada por la combinación estudiada, donde se restringe el área total ocupada por el arreglo, se sitúan los convertidores en una región de 20,000m<sup>2</sup> cada uno y se mantienen una separación mínima de 50m entre cada par de convertidor para propósitos de mantenibilidad y seguridad. Se plantean tres estrategias de solución todas basadas en algoritmos evolutivos (genéticos). La primera estrategia es la aplicación de métodos continuos (6 algoritmos), la segunda es la aplicación de métodos discretos (4 algoritmos) y la tercera es una estrategia híbrida en 5 pasos

**Paso 1.** Búsqueda local que posiciona una boya a la vez en grupos de 4 mediante algoritmos continuos. Cada conjunto de 4 boyas constituye un modelo sustituto para construir el layout completo. (Solo se tienen en cuenta interacciones entre 4 boyas?)

**Paso 2.** Construcción mediante modelos discretizados y usando el modelo sustituto o sublayout del primer paso

**Paso 3.** Inicialización inteligente (Cómo se hace?) de una población (varios arreglos basados en los subarreglos) y se codifican de forma binaria para el siguiente paso

**Paso 4.** Métodos de optimización discreta binaria a partir de las codificaciones anteriores (tres algoritmos distintos)

**Paso 5.** Aplicación de procedimiento de rotación sobre el arreglo cuando las mejoras en las poblaciones finales de los algoritmos evolutivos son mínimas (improvement rate) con el objetivo de evitar una convergencia prematura

Los algoritmos se implementaron de manera cuidadosa, de modo que se pudiese aprovechar las capacidades de paralelismo de MATLAB y el cálculo de potencia generada se basa en datos históricos acerca del clima de cada región propuesta. Estos datos permiten obtener el denominado espectro direccional del oleaje mediante el cual, usando un modelo físico se puede estimar el promedio de la potencia generada para un año. Otra métrica importante que se analiza, es el **factor q**, el cual es la razón entre la potencia total del arreglo y la suma de las potencias de cada convertidor si operaran aisladamente. Este factor puede ser mayor a 1.0 (Sería lo ideal) y representa una interferencia constructiva entre los convertidores de modo que en conjunto pueden generar más energía.

La métrica principal para la medición del desempeño del modelo de estimación y optimización es el **Ranking del Test de Friedman** con el cual se comparan las diferentes heurísticas aplicadas.

#### B. Computational intelligence in wave energy: Comprehensive review and case study [7]

Este trabajo de revisión, explora la aplicación de diversas técnicas de inteligencia computacional tanto para el modelamiento del flujo energético de las mareas como para la predicción de potencia en fases de diseño. Una de las técnicas principales que se abordan en los trabajos revisados son las redes neuronales y en ocasiones, máquinas de vectores de

soporte y aprendizaje de máquinas extremo. Esta revisión también es una ilustración de la ventaja de combinar diferentes modelos mediante un caso de estudio, enfocado principalmente a la estimación de altura significativa del oleaje, es decir, la caracterización del flujo de energía disponible de una localización.

Los diferentes métodos estudiados se presentan bajo la siguiente metodología:

1. Explicación de como la técnica se puede aplicar en el campo de "wave energy" con sus ventajas y desventajas 2. Comparación de sus resultados con los acercamientos tradicionales; es decir de modelamiento físico 3. Comparaciones en términos de los requerimientos computacionales y precisión de los métodos. Esta última comparación utiliza métricas tradicionales de regresión como es el error cuadrático medio **RMSE**, el coeficiente de correlación entre el valor real y estimado **R** y el índice de dispersión **SI** definido como la razón entre el error cuadrático medio y el promedio de la medición real (potencia)

El paper también ofrece una introducción corta a la temática de la energía undimotriz, donde se definen conceptos claves de la literatura como son la altura significativa de oleaje (significant wave height  $H_e$ ) y el periodo de energía de marea (wave energy period  $T_e$ ) los cuales se basan principalmente en modelamiento físico del fenómeno de las olas. Posteriormente describe de forma relativamente exhaustiva las diferentes tecnologías existentes que buscan aprovechar dicho potencial energético de las mareas y olas, explicando su principio de funcionamiento u operación.

Se explican de manera breve el funcionamiento de algunas de las técnicas de inteligencia computacional, a saber, el concepto de red neuronal como capas de perceptrones, el concepto ELM que consiste en asignar los pesos de la red neuronal de manera aleatoria y luego calcular la matriz inversa de las salidas de las capas ocultas, con el objetivo de acelerar el algoritmo, Las máquinas de vectores de soporte en problemas de regresión, el concepto de algoritmos genéticos y por último la programación y algoritmos basados en lógica difusa.

Para cada técnica se muestra una revisión de varios trabajos, donde son aplicadas tanto para la caracterización del potencial energético del clima de marea de una región como para el control y operación de un arreglo o layout de convertidores. Los principales hallazgos muestran como el uso de redes neuronales predicen con gran exactitud los parámetros de caracterización reportando varios trabajos resultados que varían entre 0.883 y 0.99 en el coeficiente de correlación, las máquinas de soporte obtienen valores menores en la estimación del espectro energético a pesar de obtener un error cuadrático medio.

#### IV. ENTRENAMIENTO Y EVALUACIÓN DE MODELOS

##### A. Configuración experimental

Aunque el problema planteado es la predicción de la potencia total del arreglo de convertidores y que el dataset cuenta con valores de las potencias individuales, no se pueden tomar estos valores para el modelo, ya que en general estas potencias dependen de la configuración geométrica y no solo de las características del oleaje del sitio. Por lo tanto, el problema

que se plantea es un problema de aprendizaje supervisado de única salida (Potencia total generada) a partir de las muestras que reflejan la configuración geométrica a partir de las coordenadas.

$X$ : Matriz de tamaño: número de muestras  $\times 2N$

$y$ : Vector de tamaño: número de muestras  $\times 1$

Las características del problema exigen aplicar un preprocesamiento a los datos que permitan eliminar su dependencia del ordenamiento arbitrario. Como se explicó anteriormente, cada muestra se compone de las coordenadas de los convertidores enumerados de 1 a  $N$  pero dicha enumeración podría ser cualesquiera. Para abordar esta problemática se abordaron dos estrategias de invarianza ante el orden

1 **Transformación a grid image** Consiste en transformar el layout a una imagen que represente de alguna manera la configuración geométrica establecida por las coordenadas. Como la región de búsqueda planteada es cuadrada se definieron dimensiones para la imagen de "80x80 pixeles" con la dirección de ejes naturales (horizontal de izquierda a derecha y vertical de arriba hacia abajo) y asociando entonces la esquina superior izquierda con las coordenadas  $(0, L)$  siendo  $L = \sqrt{N \cdot 20,000}$ . Cada pixel corresponde entonces a un área de dimensiones iguales a  $\Delta x = L/80 \times \Delta y = L/80$  y con una coordenada representada por la equivalencia de su centroide con el sistema de referencia que describe las posiciones de los convertidores, de este modo, las coordenadas asociadas al primer pixel, el de la esquina superior izquierda serían:  $(\Delta x/2, \Delta y/2)$ , para el siguiente pixel serían  $(\Delta x/2, 3 \cdot \Delta y/2)$  y así sucesivamente. La "Imagen Grid" se representa entonces por una matrix donde la entrada  $a_{i,j}$  que corresponde con el pixel de dicha fila  $i$  y columna  $j$  es un valor numérico obtenido de la suma de aplicar una función kernel de tipo gaussiano a partir de la distancia del "pixel" a cada convertidor:

$$a_{i,j} = \sum_{k=1}^N K(u_{(i,j)k})$$

Donde  $u_{(i,j)k}$  es la distancia del pixel  $(i, j)$  representado por sus coordenadas equivalentes a las dimensiones del posicionamiento y la posición del convertidor  $k$  y la función kernel gaussiana es de la forma:

$$K(x) = \exp\left(-\frac{x^2}{2\gamma^2}\right)$$

Este Kernel busca explicar la influencia que puede tener un convertidor a su alrededor por radiación de ondas provenientes de su interacción con las olas.

Esta transformación tiene un par de ventajas que se buscan explotar en los modelos

o **Normalización:** Para cualquier conjunto de convertidores, esta estrategia convierte la información en una misma representación, una imagen de 80x80 por lo cual, sería posible entrenar un modelo para cada sitio con la información de los conjuntos tanto de  $N = 49$  como de  $N = 100$  convertidores.

- o **Invarianza.** La representación como una imagen garantiza de inmediato la invarianza al ordenamiento aleatorio de los convertidores.

A pesar de las ventajas descritas, una desventaja fundamental es que el espacio de características que se crea no se relaciona de forma tan directa con la ubicación específica de los convertidores aunque si hace una captura de dicha información, no es posible identificar las posiciones que más influyen en la potencia final generada. Otra desventaja que exige un paso de procesamiento adicional es la magnitud de características generado  $80 \times 80 = 6,400$  por lo que se busca una reducción de dimensión luego de dicha transformación.

## 2 Ingeniería de características

Esta estrategia consiste en la aplicación de dos operaciones

**2.1 Ordenamiento Canónico** Se reordenaron espacialmente las coordenadas  $(X, Y)$  de cada granja de Oeste a Este. Esto garantizó que la columna  $X_1$  siempre correspondiera al convertidor más occidental, proporcionando una estructura topológica consistente para que los modelos aprendieran patrones espaciales.

**2.2 Ingeniería de características "Physics informed"** Además de las 200 coordenadas puras, se generaron variables sintéticas para capturar la física del problema:

- o **Potencial de interacción:** Sumatoria inversa de distancias ( $\sum 1/d_{ij}$ ) para simular el efecto de interferencia de olas entre boyas
- o **Momentos de Inercia** ( $I_{xx}, I_{yy}$ ): Para caracterizar la dispersión y forma geométrica de la granja.
- o **Convex Hull y Densidad** Para medir el área efectiva ocupada y el compactamiento de los dispositivos.
- o **Gradiente de Profundidad** Diferencia promedio entre la primera y última fila de boyas.

Posterior al preprocesamiento se busca resolver el problema usando distintos modelos de regresión:

- o **Regresión Lineal** Este se aplicó a los datos sin transformar como punto de partida y sobre los datos transformados mediante la técnica del Grid Image. El hiperparámetro identificado para este modelo es únicamente el valor de  $\gamma$  a usar en la función kernel. Inicialmente se hicieron pruebas con un valor  $\gamma = 50$  asociado a la distancia mínima entre convertidores.
- o **Gradient-Boosting basado en histograma:** Los hiperparámetros asociados a este modelo son: el learning rate, número máximo de iteraciones (árboles), max depth (profundidad máxima de cada árbol) y regularización tipo L2.
- o **Modelo de red neuronal MLP:** Se definen dos capas ocultas y regularización L2, por lo tanto los hiperparámetros en este modelo son el número de neuronas en cada capa y el coeficiente de regularización. Para el entrenamiento se usa la técnica del early stopping

- o **XGBoost:**
- o **SVR:**

## B. Resultados del entrenamiento de modelos

Para la estrategia de transformación de grid image se aplicó una regresión lineal posterior al preprocesamiento. Para comparar resultados se aplicó primero una regresión lineal al conjunto de datos en "crudo" y se obtuvieron las métricas más representativas como el error cuadrático medio (RSME), el error porcentual absoluto medio (MAPE) y el coeficiente de determinación.

Tabla II  
REGRESIÓN LINEAL SOBRE LOS DATOS ORIGINALES

Parámetro	Valor
Coficiente de determinación train ( $R^2$ )	0.8323
RSME train (W)	50,263.28
MAPE train (0.94)	
Coficiente de determinación test ( $R^2$ )	0.8328
RSME test (W)	49,996.37
MAPE test (0.94)	

Resultados para el dataset correspondiente a Peth con  $N = 49$

Como se observa, los resultados son bastante buenos con errores porcentuales muy pequeños, lo cual demuestra que la relación de los datos es altamente lineal, debido al origen de los datos como simulaciones a partir de modelos físicos simplificados. Aunque estos resultados son buenos, el modelo sin transformación no es inmune frente a otro esquema de enumeramiento, pues no permite la invarianza, por ejemplo al aplicar un procedimiento de reordenamiento de coordenadas los resultados que se obtienen son los siguientes

Tabla III  
REGRESIÓN LINEAL SOBRE LOS DATOS ORIGINALES AL REORDENAR

Parámetro	Valor
Coficiente de determinación train ( $R^2$ )	0.0740
RSME train (W)	118,121.33
MAPE train (%)	2.53
Coficiente de determinación test ( $R^2$ )	0.0645
RSME test (W)	118,275.68
MAPE test (%)	2.54

Resultados para el dataset correspondiente a Peth con  $N = 49$

A continuación se presentan los resultados de aplicar un preprocesamiento consistente en obtención de un grid image

con  $\gamma = 50$ , se encontró el número óptimo de componentes para una descomposición PCA que conserve al menos el 90% de la varianza explicada obteniendo como parámetro un número de componentes de 42. Los resultados obtenidos son muy similares a los de la regresión sobre los datos "crudos" pero estos si son invariantes al orden

Tabla IV  
REGRESIÓN LINEAL SOBRE LOS DATOS ORIGINALES AL REORDENAR

Parámetro	Valor
Coefficiente de determinación train ( $R^2$ )	0.8521
RSME train (W)	47,213.97
MAPE train (%)	0.87
Coefficiente de determinación test ( $R^2$ )	0.8492
RSME test (W)	47,487.34
MAPE test (%)	0.88

Resultados para el dataset correspondiente a Peth con  $N = 49$

#### REFERENCIAS

- [1] Neshat, Mehdi et al. "Optimisation of large wave farms using a multi-strategy evolutionary framework." *Proceedings of the 2020 Genetic and Evolutionary Computation Conference (2020)*. [Online].
- [2] Mohammad Mehdi et al. "Multi-objective evolutionary framework for layout and operational optimization of a multi-body wave energy converter." *Energy*, vol. 313, 2024, 134045, ISSN 0360-5442. DOI: [10.1016/j.energy.2024.134045](https://doi.org/10.1016/j.energy.2024.134045).
- [3] Sergiienko, Nataliia et al. (2016). "Three-Tether Axisymmetric Wave Energy Converter: Estimation of Energy Delivery." *Proceedings of the 3-rd Asian Wave and Tidal Energy Conference (AWTEC 2016) vol. 1 (2016)*. 10.3850/978-981-11-0782-5\_65. . DOI: 10.3850/978-981-11-0782-5\_65.
- [4] M. Neshat, B. Alexander, M. Wagner, and Y. Xia, "A detailed comparison of meta-heuristic methods for optimising wave energy converter placements," *Proceedings of the Genetic and Evolutionary Computation Conference (GECCO '18)*, pp. 1318–1325, 2018.
- [5] Sergiienko, Nataliia, Ding, Boyin and Cazzolato, Ben. (2016). Frequency domain model of the three-tether WECs array. 10.13140/RG.2.1.1917.0324.
- [6] , G., et al. (2021). "Short-term wave power prediction based on hybrid deep learning model of LSTM, GRU and Bi-LSTM." *Renewable Energy*, 178, 387–402. DOI: [10.1016/j.renene.2021.06.074](https://doi.org/10.1016/j.renene.2021.06.074)
- [7] , ZL Cuadra, S Salcedo-Sanz, JC Nieto-Borge, E Alexandre, and G Rodriguez. Computational intelligence in wave energy: Comprehensive review and case study. *Renewable and Sustainable Energy Reviews*, 58:1223–1246, 2016.